



HCMUS

Viet Nam National University
Ho Chi Minh City
University of Science

CS418 - Natural Language Processing

Mid-term Project

29 - Vietnamese Knowledge Graph

23APCS1

Team Members:

23125053 - Lê Tấn Nguyên Đạt

23125070 - Nguyễn Công Viết Thành

23125035 - Trần Nguyễn Đức Tâm

23125086 - Vầy Thượng Gia Lạc

Contents

1	Introduction	3
1.1	Overview	3
1.2	Motivation and Challenges	3
1.2.1	Source Material Characteristics	3
1.3	Project Objectives	4
2	Methodology	5
2.1	Approach and Corpus Strategy	5
2.1.1	Adaptive Image Preprocessing	5
2.1.2	Layout-Aware Content Extraction	5
2.1.3	LLM-Based Error Correction	6
3	Processing Pipeline	7
3.1	System Architecture	7
3.1.1	Component 1: PDF to Image Conversion	7
3.1.2	Component 2: Layout Analysis	7
3.1.3	Component 3: Image Preprocessing	7
3.1.4	Component 4: Layout-Aware Masking	8
3.1.5	Component 5: LLM-Based Cleanup	8
3.2	Data Flow Summary	8
4	Algorithms and Technologies	9
4.1	Key Algorithms	9
4.1.1	Adaptive Gaussian Thresholding	9
4.1.2	Smart Bounding Box Handling	9
4.2	Technologies Used	9
5	Results and Data Statistics	10
5.1	Source Documents	10
5.2	Processing Results	10
5.3	Example 1: Y Dược truyền thống Trung Quốc Page	10
5.4	Example 2: 250 bài thuốc Đông y	13
6	Discussion	16
6.1	Our Challenges and Solutions	16
6.1.1	Blurred Images	16
6.1.2	Sino-Vietnamese Words	16
6.1.3	Complex Layouts	16
6.2	Limitations and Future Work	16

6.3	Conclusion	17
-----	----------------------	----

Chapter 1

Introduction

1.1 Overview

This project focuses on constructing a knowledge graph from traditional medicine documents through automated text and layout analysis. Two sources were used:

1. **Y Dược truyền thống Trung Quốc** - A comprehensive illustrated textbook containing 150 pages with dense medical content and visual diagrams.
2. **250 bài thuốc Đông y** - A text-heavy reference document with 877 pages containing detailed herbal prescriptions and remedies with minimal visual content.

The goal is to automatically extract, structure, and clean both text and visual elements from these documents to build a queryable knowledge graph of traditional medicine formulations and practices.

1.2 Motivation and Challenges

1.2.1 Source Material Characteristics

Y Dược truyền thống Trung Quốc

- **Visual-Rich Content:** Contains numerous medical diagrams, charts, and anatomical illustrations
- **Image Quality Issues:** Multiple pages exhibit blur and degradation from PDF compression
- **Small Typography:** Annotations and captions are often rendered at very small font sizes
- **Complex Layout:** Mixed text, tables, figures, and formulas on single pages

250 bài thuốc Đông y

- **Text-Focused:** Minimal illustrations; primarily composed of prescriptions and therapeutic descriptions
- **High Print Quality:** Clear, sharp typography making OCR theoretically simpler

- Specialized Vocabulary: Extensive use of Sino-Vietnamese terminology requiring high spelling accuracy
- Complex Medical Semantics: Terms often have multiple meanings and require precise interpretation

1.3 Project Objectives

1. Convert PDF documents to high-resolution images for processing
2. Perform layout analysis to separate text from visual elements
3. Extract and preserve images, tables, charts, and formulas
4. Apply advanced OCR with preprocessing optimized for blurred and small text
5. Leverage Large Language Models to correct OCR errors and validate spelling
6. Organize extracted data into structured, queryable format

Chapter 2

Methodology

2.1 Approach and Corpus Strategy

Given the heterogeneous nature of our source materials, we developed a two-pronged processing strategy:

2.1.1 Adaptive Image Preprocessing

Since the Traditional Chinese Medicine textbook contains significant image quality variations (blur, noise, small text), we implemented a sophisticated image preprocessing pipeline:

- Grayscale Conversion: Reduces color space complexity
- Upscaling (2x): Magnifies small text and annotations using cubic interpolation to preserve quality
- Adaptive Gaussian Thresholding: Handles varying lighting conditions across pages
- Block-based Processing: Uses 31x31 block size for robust threshold computation

This approach significantly improves OCR accuracy on degraded document images while maintaining legibility of sharp text in the Vietnamese remedies book.

2.1.2 Layout-Aware Content Extraction

Rather than treating all content uniformly, we use intelligent segmentation:

- Layout Detection: Identifies regions containing text, images, tables, equations, headers, and footers
- Selective Masking: Temporarily removes non-text elements before OCR
- Element Preservation: Saves all removed elements separately with metadata
- Clean OCR: Operates on masked images to prevent garbage text generation

2.1.3 LLM-Based Error Correction

Post-OCR, we leverage Google Gemini 2.5 Flash API for:

- Spelling Correction: Fixes OCR errors while preserving original meaning
- Terminology Validation: Ensures proper spelling of complex terms
- Punctuation Normalization: Corrects formatting errors introduced by OCR
- Context-Aware Cleaning: Maintains section titles, indices, and list structures

Chapter 3

Processing Pipeline

3.1 System Architecture

The processing pipeline consists of five main components working in sequence.

3.1.1 Component 1: PDF to Image Conversion

Converts each PDF page into high-resolution PNG images at 300 DPI using PyMuPDF.

Configuration:

- Input: PDF documents from source directory
- Output DPI: 300 DPI (suitable for fine details and computational efficiency)
- Format: PNG (lossless compression)
- Organization: One folder per document containing all page images

3.1.2 Component 2: Layout Analysis

Uses PaddleX PPStructureV3 model configured for Vietnamese language support.

Element Classification:

- text, header, footer: Extract and clean text
- figure, chart: Save as individual images
- table: Convert to HTML format
- equation, formula: Save as images
- captions: Extract separately with OCR

3.1.3 Component 3: Image Preprocessing

Pipeline Steps:

1. Grayscale Conversion
2. 2x Upscaling using cubic interpolation

3. Adaptive Gaussian Thresholding (block size 31, constant 15)

Rationale:

- Adaptive Thresholding: Better handles varying illumination
- Gaussian vs Mean: More robust to noise
- Block Size 31: Balances lighting variation and detail preservation
- Upscaling: Critical for small annotations

3.1.4 Component 4: Layout-Aware Masking

Content-Specific Strategy:

- Images/Figures/Charts: Extract separately before masking
- Tables: Save HTML representation before masking
- Equations/Formulas: Save as images before masking
- Captions: OCR individually
- Body Text: OCR on masked image

3.1.5 Component 5: LLM-Based Cleanup

Uses Google Generative AI API for post-OCR correction with specialized prompts for medical terminology.

3.2 Data Flow Summary

1. PDF documents to PNG images (300 DPI)
2. PNG images to PaddleX layout analysis
3. Layout detection to selective extraction
4. Page images to preprocessing (grayscale, upscale, adaptive threshold)
5. Masked images to Tesseract OCR
6. Raw OCR text to Google Gemini LLM
7. Cleaned text and extracted elements to output folders

Chapter 4

Algorithms and Technologies

4.1 Key Algorithms

4.1.1 Adaptive Gaussian Thresholding

Converts grayscale image to binary while handling uneven illumination:

$$T(x, y) = \begin{cases} 255 & \text{if } I(x, y) > \text{Mean}(x, y) - C \\ 0 & \text{otherwise} \end{cases}$$

Where the mean is computed over a Gaussian-weighted neighborhood.

4.1.2 Smart Bounding Box Handling

Implements robust coordinate handling for extracted regions:

- Floor operation: Top-left coordinates
- Ceiling operation: Bottom-right coordinates
- Padding: Add 5-10 pixels to prevent cutting off text edges
- Boundary clamping: Ensure coordinates stay within image bounds

4.2 Technologies Used

- PyMuPDF: PDF to image conversion
- OpenCV: Image processing and preprocessing
- Tesseract OCR: Optical character recognition
- PaddleX PPStructureV3: Layout analysis and element detection
- PIL/Pillow: Image I/O and manipulation
- Google Gemini 2.5 Flash: LLM-based text correction with medical terminology awareness
- NumPy: Numerical operations on image arrays

Chapter 5

Results and Data Statistics

5.1 Source Documents

Input Dataset:

- Y Dược truyền thống Trung Quốc Textbook: 150 pages
- 250 bài thuốc đông y: 877 pages
- **Total: 1027 pages**

5.2 Processing Results

Summary:

- Output Folders: 1027 page folders
- Raw OCR Text Files: 1027 txt files
- LLM-Corrected Text Files: 1027 spellfix.txt files
- Total Text Files: 2054 files
- Extracted Images: 147 images
- Total Storage: $\approx 15MB$

5.3 Example 1: Y Dược truyền thống Trung Quốc Page

Original: Sample page with mixed text and medical diagrams, blurred sections, complex layout.

văn hóa, bản thân nó không hề dồn ép Trung y, mà ngược lại nó khuyến khích và tạo cơ hội cho Trung y phát triển.

Trong giai đoạn giao thoa văn hóa Trung y và Tây y đặc biệt này, năm 1958 Bộ Y tế đã ủy thác cho Học viện Trung y Nam Kinh và những nơi khác biên soạn tài liệu mới về Trung y, có thể nói đây là bước ngoặt lớn trong lịch sử. Từ đó mới có môn “Khái luận Trung y học”, có phạm trù và khái niệm của “lí luận cơ bản Trung y”. Có thể nói rằng việc biên soạn giáo trình mới cũng chính là chỉnh lí hệ thống kiến thức Trung y, hay nói đúng hơn là hệ thống hóa kiến thức từ những kiến thức phức tạp và lộn xộn, chọn lọc những nội dung mấu chốt mang tính hạt nhân để làm “hệ thống cơ bản” của y học truyền thống. Mấy mươi năm qua, giáo trình dạy Trung y đã qua nhiều lần sửa đổi, nhưng nội dung và cấu trúc không thay đổi nhiều.

Trong cấu trúc y học mới này, thì “Học thuyết Kinh Lạc” không bao hàm những mô tả trong “Hoàng Đế nội kinh” như “Những đường hiện ra trên cơ thể có thể thấy được gọi là mạch lạc, cái gì ẩn ở bên trong gọi là kinh mạch”, “mạch có màu xanh là hàn, màu đỏ là nhiệt và nổi rõ, lúc phủ



Sau khi Tây y du nhập vào Trung Quốc thì dần dần đã quen thuộc với người dân. Đây là mẫu quảng cáo thuốc vào những năm 30 của thế kỷ XX.

ngủ tạng được định nghĩa thành một “đơn vị sinh lý” - tức là khí tạng trong giải phẫu học không giống và đúng với cách gọi tên so sánh với các vị quan trọng triều đình như trước. Châm cứu học cũng không bao gồm những bệnh của “ngoại trị pháp” như chích mổ u nhọt và được gọi là phương pháp trị liệu bằng cách thông qua vật lý trị liệu để điều chỉnh, chứa trị sự vận hành của khí huyết và tạng phủ”. Đồng thời, khái quát thành những đặc điểm cơ bản của trị liệu học trong Trung y để làm rõ những nét khác biệt với Tây y, đó là “biện chứng thi trị”, tức là căn cứ vào những biểu hiện của cơ thể, bệnh trạng mà tổng hợp lại và tìm phương pháp điều trị cho triệu chứng “chứng” bệnh (như: hư, thực,



Figure 5.1: Original Y Dược truyền thống Trung Quốc page with complex layout

Extracted Elements: Medical diagrams, formulas, and charts saved separately.



Figure 5.2: Example of extracted medical diagram from Y Dược truyền thống Trung Quốc page

Raw OCR Output vs Final Output: Comparison showing LLM correction effectiveness.

Tiếp cận với Trung y

văn hóa, bản thân nó không hề dồn ép Trung y, mà ngược lại nó khuyến khích và tạo cơ hội cho Trung y phát triển.

Trong giai đoạn giao thoa văn hóa Trung y và Tây y đặc biệt này, năm 1958 Bộ Y tế đã ủy thác cho Học viện Trung y Nam Kinh và những nơi khác biên soạn tài liệu mới về Trung y, có thể nói đây là bước ngoặt lớn trong lịch sử. Từ đó mới có môn "Khái luận Trung y học" có phạm trù và khái niệm của "lý luận cơ bản Trung y" Có thể nói rằng việc biên soạn giáo trình mới cũng chính là chỉnh lý hệ thống Kiến thức Trung y, hay nói đúng hơn là hệ thống hóa kiến thức từ những kiến thức phức tạp và lộn xộn, chọn lọc những nội dung mấu chốt mang tính hạt nhân để làm "hệ thống cơ bản" của y học truyền thống. Mấy mươi năm qua, giáo trình dạy Trung y đã qua nhiều lần sửa đổi, nhưng nội dung và cấu trúc không thay đổi nhiều.

Trong cấu trúc y học mới này, thì "Học thuyết Kinh Lạc" không bao hàm những mô tả trong "Hoàng Đế nội kinh" như "Những đường hiện ra trên cơ thể có thể thấy được gọi là mạch lạc, cái gì ẩn ở bên trong gọi là kinh mạch" "mạch có màu xanh là hàn, màu đỏ là nhiệt và nói rõ, lục phủ ngũ tạng được định nghĩa thành một "đơn vị sinh lý" - tức là khí tạng trong giải phẫu học không giống và đúng với cách gọi tên so sánh với các vị quan trọng triều đình như trước. Chăm cứu học cũng không bao gồm những bệnh của "ngoại trị pháp" như chích mổ u nhọt và được gọi là phương pháp trị liệu bằng cách thông qua vật lý trị liệu để điều chỉnh, chữa trị sự vận hành của khí huyết và tạng phủ" Đồng thời, khái quát thành những đặc điểm cơ bản của trị liệu học trong Trung y để làm rõ những nét khác biệt với Tây y, đó là "biện chứng thì trị", tức là

: căn cứ vào những biểu hiện của cơ thể, bệnh trạng mà tổng hợp và tìm phương pháp điều trị cho triệu chứng "chứng" bệnh (như: hư, thực,

Figure 5.3: *

(a) Raw OCR output with errors

Tiếp cận với Trung y

văn hóa, bản thân nó không hề dồn ép Trung y, mà ngược lại nó khuyến khích và tạo cơ hội cho Trung y phát triển.

Trong giai đoạn giao thoa văn hóa Trung y và Tây y đặc biệt này, năm 1958 Bộ Y tế đã ủy thác cho Học viện Trung y Nam Kinh và những nơi khác biên soạn tài liệu mới về Trung y, có thể nói đây là bước ngoặt lớn trong lịch sử. Từ đó mới có môn "Khái luận Trung y học" có phạm trù và khái niệm của "lý luận cơ bản Trung y". Có thể nói rằng việc biên soạn giáo trình mới cũng chính là chỉnh lý hệ thống kiến thức Trung y, hay nói đúng hơn là hệ thống hóa kiến thức từ những kiến thức phức tạp và lộn xộn, chọn lọc những nội dung mấu chốt mang tính hạt nhân để làm "hệ thống cơ bản" của y học truyền thống. Mấy mươi năm qua, giáo trình dạy Trung y đã qua nhiều lần sửa đổi, nhưng nội dung và cấu trúc không thay đổi nhiều.

Trong cấu trúc y học mới này, thì "Học thuyết Kinh Lạc" không bao hàm những mô tả trong "Hoàng Đế nội kinh" như "Những đường hiện ra trên cơ thể có thể thấy được gọi là mạch lạc, cái gì ẩn ở bên trong gọi là kinh mạch" "mạch có màu xanh là hàn, màu đỏ là nhiệt và nói rõ, lục phủ ngũ tạng được định nghĩa thành một "đơn vị sinh lý" - tức là khí tạng trong giải phẫu học không giống và đúng với cách gọi tên so sánh với các vị quan trọng triều đình như trước. Chăm cứu học cũng không bao gồm những bệnh của "ngoại trị pháp" như chích mổ u nhọt và được gọi là phương pháp trị liệu bằng cách thông qua vật lý trị liệu để điều chỉnh, chữa trị sự vận hành của khí huyết và tạng phủ". Đồng thời, khái quát thành những đặc điểm cơ bản của trị liệu học trong Trung y để làm rõ những nét khác biệt với Tây y, đó là "biện chứng thì trị", tức là

: căn cứ vào những biểu hiện của cơ thể, bệnh trạng mà tổng hợp và tìm phương pháp điều trị cho triệu chứng "chứng" bệnh (như: hư, thực,

Figure 5.4: *

(b) Final output after LLM correction

Figure 5.5: Comparison of raw OCR output and final cleaned output for Y Dược truyền thống Trung Quốc

5.4 Example 2: 250 bài thuốc Đông y

Original: Dense text with specialized terminology, clear typography, list-based format.

ĐẠI THANH LONG THANG
(Thương hàn luận)

Thành phần:

Ma hoàng 16 g
Chích thảo 8 g
Thạch cao 32 g
Đại táo 4 quả
Quế chi 8 g
Hạnh nhân 8 g
Sinh khương 8 g

Cách dùng: Thạch cao sắc trước, thuốc sắc chia 3 lần, uống trong ngày, ra mồ hôi nhiều ngưng dùng thuốc.

Tác dụng: Phát hãn, giải biểu, thanh nhiệt, trừ phiền.

Trị các chứng ngoại cảm phong hàn biểu thực kèm lý nhiệt chứng thường thấy sốt sợ lạnh, đầu nặng, mình đau không ra mồ hôi, khó chịu, rêu lưỡi trắng hoặc hơi vàng, mạch phù khẩn có lực.

Giải thích bài thuốc: Bài thuốc được tạo thành trên cơ sở bài Ma hoàng thang gia tăng lượng Ma hoàng và Cam thảo, có thêm Thạch cao, Gừng và Táo.

- Tăng lượng Ma hoàng để tăng tác dụng phát hãn và giải biểu.
- Thạch cao: thanh nhiệt trừ phiền.
- Thêm lượng Cam thảo để điều hòa trung khí.
- Thêm Khương, Táo để điều hòa vịnh vệ.

Ứng dụng lâm sàng:

Bài thuốc được sử dụng chủ yếu đối với chứng sốt sợ lạnh, không ra mồ hôi, bứt rứt khó chịu mà mạch phù khẩn có lực.

Bài thuốc cũng có thể dùng trong các trường hợp vốn cơ thể đàm ẩm, ho suyễn do cảm thụ ngoại tà gây nên, chân tay phù sốt, sợ lạnh không ra mồ hôi, bứt rứt khó chịu.

Chú ý lúc sử dụng:

Bài thuốc tác dụng phát hãn mạnh dễ thương âm dương nên không dùng được với những người hư nhược.

Figure 5.6: Original 250 bài thuốc Đông y page

Raw OCR Output vs Final Output: Comparison showing LLM correction effectiveness.

DAI THANH LONG THANG
(Thương hàn luận)

Thành phần:

Ma hoàng 16g
Chích thảo 8g
Thạch cao 32g
Đại táo 4 quả
Quế chi 8g

Hành nhân 8g
Sinh khương 8g

Cách dùng: Thạch cao sắc trước, thuốc sắc chia 3 lần, uống trong ngày, ra mồ hôi nhiều ngưng dùng thuốc.

Tác dụng: Phát hãn, giải biểu, thanh nhiệt, trừ phiền.

Trị các chứng ~~ngau~~ cảm phong hàn biểu ~~thực~~ kiểm lý nhiệt ~~wang~~ thường thấy sốt sợ lạnh, đầu nặng, mình đau không ra mồ hôi, khó chịu, rêu lưỡi trắng hoặc hơi vàng, mạch phù khẩn có lực.

Giải thích bài thuốc: Bài thuốc được tạo thành trên cơ sở bài Ma hoàng thang gia tăng lượng Ma hoàng và Cam thảo, có thêm Thạch cao, Gừng và Táo.

* Tăng lượng Ma hoàng để tăng tác dụng phát hãn và giải biểu.

o Thạch cao: thanh nhiệt trừ phiền.

* Thêm lượng Cam thảo để điều hòa trung khí.

* Thêm Khương, Táo để điều hòa vinh vệ.

Ứng dụng lâm sàng:
Bài thuốc được sử dụng chủ yếu đối với chứng sốt sợ lạnh, không ra mồ hôi, bứt rứt khó chịu mà mạch phù khẩn có lực.
Bài thuốc cũng có thể dùng trong các trường hợp vốn cơ thể đàm ẩm, ho suyễn do cảm thụ ngoại tà gây nên, chân tay phù sốt, sợ lạnh không ra mồ hôi, bứt rứt khó chịu.
Chú ý lúc sử dụng:
Bài thuốc tác dụng phát hãn mạnh dễ thương âm dương nên không dùng được với những người hư nhược.

Figure 5.7: *

(a) Raw OCR output with terminology errors

DAI THANH LONG THANG
(Thương hàn luận)

Thành phần:

Ma hoàng 16g
Chích thảo 8g
Thạch cao 32g
Đại táo 4 quả
Quế chi 8g

Hành nhân 8g
Sinh khương 8g

Cách dùng: Thạch cao sắc trước, thuốc sắc chia 3 lần, uống trong ngày, ra mồ hôi nhiều ngưng dùng thuốc.

Tác dụng: Phát hãn, giải biểu, thanh nhiệt, trừ phiền.

Trị các chứng ngoại cảm phong hàn biểu thực kiểm lý nhiệt thường thấy sốt sợ lạnh, đầu nặng, mình đau không ra mồ hôi, khó chịu, rêu lưỡi trắng hoặc hơi vàng, mạch phù khẩn có lực.

Giải thích bài thuốc: Bài thuốc được tạo thành trên cơ sở bài Ma hoàng thang gia tăng lượng Ma hoàng và Cam thảo, có thêm Thạch cao, Gừng và Táo.

<begin items>
... Tăng lượng Ma hoàng để tăng tác dụng phát hãn và giải biểu.
o Thạch cao: thanh nhiệt trừ phiền.
o Thêm lượng Cam thảo để điều hòa trung khí.
o Thêm Khương, Táo để điều hòa vinh vệ.
<end items>
Ứng dụng lâm sàng:
Bài thuốc được sử dụng chủ yếu đối với chứng sốt sợ lạnh, không ra mồ hôi, bứt rứt khó chịu mà mạch phù khẩn có lực.
Bài thuốc cũng có thể dùng trong các trường hợp vốn cơ thể đàm ẩm, ho suyễn do cảm thụ ngoại tà gây nên, chân tay phù sốt, sợ lạnh không ra mồ hôi, bứt rứt khó chịu.
Chú ý lúc sử dụng:
Bài thuốc tác dụng phát hãn mạnh dễ thương âm dương nên không dùng được với những người hư nhược.

Figure 5.8: *

(b) Final output with corrected terminology

Figure 5.9: Comparison of raw OCR output and final cleaned output for 250 bài thuốc Đông y

Chapter 6

Discussion

6.1 Our Challenges and Solutions

6.1.1 Blurred Images

Problem: Y Dược truyền thống Trung Quốc textbook has blurred pages and small annotations with different layouts.

Solution: 2x upscaling with cubic interpolation, adaptive Gaussian thresholding, layout masking.

6.1.2 Sino-Vietnamese Words

Problem: OCR misidentifies specialized term related to Sino-Vietnamese and some Vietnamese notations in spelling, character error and punctuations.

Solution: Using Google Gemini LLM with specialized prompts, context validation, semantic preservation.

6.1.3 Complex Layouts

Problem: Mixed content with images structure causes OCR suffering in detect what is content or image(and its label).

Solution: PaddleX layout detection, selective masking, separate caption processing.

6.2 Limitations and Future Work

Current Limitations:

- Complex formula recognition challenges
- LLM API latency for large documents

Our potential Enhancements in the future:

1. Knowledge Graph Construction
2. Named Entity Recognition
3. Cross-Document Linking

4. Confidence Scoring
5. Parallel Processing Optimization

6.3 Conclusion

This project demonstrates an end-to-end pipeline for extracting structured information from heterogeneous document collections using modern OCR, layout analysis, and large language models.

The combination of advanced image preprocessing, layout-aware content extraction, strategic masking, and LLM-based error correction enables robust processing of both image-heavy and text-heavy traditional medicine documents.

The resulting structured data provides a foundation for constructing a comprehensive knowledge graph of traditional medicine formulations and therapeutic applications.